

ANEXO I, DO REGULAMENTO DE TRABALHO DE CONCLUSÃO DE CURSO, TCC, DO CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO DA UNIVERSIDADE ESTADUAL DO CENTRO-OESTE, UNICENTRO

PROPOSTA DE PROJETO DE TRABALHO DE CONCLUSÃO DE CURSO – TCC

1) PROPONENTES:

a) Discente:

Nome: Herich Gabriel de Campos

Telefone: (42) 988522674

E-mail: 57023740007@unicentro.edu.br

b) Orientador(a):

Nome: Josiel Neumann Kuk

Titulação: Doutorado

Telefone: (42) 999166284

E-mail: josiel@unicentro.br

2) IDENTIFICAÇÃO DA PROPOSTA

TÍTULO: Desenvolvimento e Análise de Agentes de Inteligência Artificial em um Ambiente Simulado de Teamfight Tactics

TIPO DE TRABALHO: () DESENVOLVIMENTO DE SISTEMAS (X) PESQUISA

RESUMO:

O jogo Teamfight Tactics (TFT) apresenta desafios complexos para a Inteligência Artificial devido à sua natureza estocástica, ao gerenciamento de economia e às dinâmicas de composição de equipes em um lobby competitivo de múltiplos jogadores. Atualmente, observa-se uma escassez de agentes inteligentes capazes de jogar o jogo de forma estratégica e adaptativa em alto nível, dificuldade atribuída à longa duração das partidas oficiais e ao código fechado do cliente. O propósito deste trabalho é desenvolver um ambiente de simulação simplificado e acelerado do jogo, implementando um subconjunto de aproximadamente 30 campeões com habilidades abstraídas, e utilizá-lo para treinar e comparar três classes de agentes: heurísticas fixas (baseline), agentes baseados em Algoritmos Genéticos e agentes baseados em Aprendizado por Reforço (RL). O ambiente será desenvolvido em C++ com bindings para Python, garantindo a performance necessária para milhares de iterações de treinamento. Os agentes de RL observarão um estado rico do jogo, incluindo composição do próprio tabuleiro, peças disponíveis na loja, unidades no banco e as composições dos adversários, para aprender a tomar decisões adaptativas como contestar ou abandonar uma composição com base na disputa do lobby. Espera-se, como resultado, demonstrar que agentes de Aprendizado por Reforço superam heurísticas fixas e agentes evolutivos na tomada de decisão dinâmica característica do gênero auto-battler.

PALAVRAS-CHAVE: *Inteligência Artificial; Aprendizado por Reforço; Simulação; Auto-battler; Algoritmos Genéticos.*

3) PROPOSTA DE TRABALHO

Esta seção apresenta a fundamentação, os objetivos e o planejamento do trabalho proposto, detalhando o problema abordado, as técnicas a serem investigadas e a metodologia de desenvolvimento adotada.

3.1 DESCRIÇÃO

A presente proposta consiste no desenvolvimento e análise de agentes inteligentes aplicados ao jogo Teamfight Tactics (TFT). O trabalho se centrará na construção de um ambiente de simulação simplificado e acelerado, abstraindo a renderização gráfica do cliente oficial para focar exclusivamente nas regras lógicas, mecânicas de economia e sistema de composição de equipes. O ambiente incluirá aproximadamente 30 campeões com habilidades simplificadas, preservando a diversidade estratégica do jogo sem a complexidade de implementar o catálogo completo de habilidades. O motor de simulação será desenvolvido em C++ e exposto via bindings para Python, garantindo alta performance para o volume de iterações necessário ao treinamento dos agentes.

A realização deste projeto justifica-se pela relevância do gênero auto-battler, que conta com mais de 33 milhões de jogadores mensais [Henkel 2019], e pela atual escassez de estudos aprofundados sobre agentes capazes de jogar partidas completas em alto nível. Embora existam iniciativas isoladas focadas em posicionamento [Liu 2022] ou aprendizado por reforço em versões simplificadas [Zhang 2024], ainda há uma lacuna significativa em agentes que tomem decisões econômicas e estratégicas de forma dinâmica e reativa ao estado do lobby. O simulador acelerado permitirá a execução de milhares de partidas completas, viabilizando o treinamento de agentes que, no ambiente oficial, seria computacionalmente inviável.

O aspecto central e diferenciador deste trabalho é a modelagem da tomada de decisão de composição como um problema de aprendizado sequencial sob incerteza, formalizado como um Processo de Decisão de Markov [Sutton e Barto 2018]. Em TFT, a decisão de investir em uma determinada composição de campeões depende não apenas do estado interno do jogador, mas do estado do lobby: se outros jogadores estão disputando as mesmas peças (contestando a composição), o valor esperado de insistir nela cai significativamente. O agente de Aprendizado por Reforço será treinado para identificar e reagir a esses padrões de forma autônoma.

3.2 OBJETIVOS

Os objetivos a seguir delimitam o escopo científico e técnico do trabalho, organizados em um objetivo geral e objetivos específicos que orientarão cada etapa do desenvolvimento.

3.2.1 Objetivo Geral

Analisar e comparar o desempenho de diferentes técnicas de Inteligência Artificial (heurísticas fixas, Algoritmos Genéticos e Aprendizado por Reforço) na tomada de decisão

estratégica adaptativa no jogo Teamfight Tactics, com ênfase no gerenciamento de economia e na escolha dinâmica de composições em um ambiente multi-agente.

3.2.2 Objetivos Específicos

- Desenvolver um motor de simulação em C++ com interface Python que reproduza as mecânicas principais do TFT: loja, sistema de ouro e juros, nivelamento, combate automático simplificado e traits de campeões, utilizando um conjunto de aproximadamente 30 campeões com habilidades abstraídas.
- Implementar agentes de controle baseados em heurísticas fixas (ex.: sempre maximizar juros; sempre comprar o campeão de maior custo disponível) para servir de baseline de comparação.
- Implementar agentes baseados em Algoritmos Genéticos, nos quais cada indivíduo representa um vetor de preferências por composições e estratégias econômicas, servindo como patamar intermediário de comparação.
- Implementar um agente baseado em Aprendizado por Reforço (DQN ou PPO) capaz de observar o estado rico do jogo, incluindo composição própria, loja, banco e composições dos adversários, e aprender a tomar decisões adaptativas como contestar, pivotar ou forçar uma composição.
- Realizar experimentos comparativos em torneios simulados entre as três classes de agentes para avaliar métricas de desempenho como taxa de vitória, colocação média e eficiência econômica.

3.3 DIFERENCIAL EM CIÊNCIA DA COMPUTAÇÃO

Esta seção apresenta a relação do trabalho com as disciplinas do curso de Bacharelado em Ciência da Computação, justificando seu enquadramento acadêmico

3.3.1 Enquadramento

- Inteligência Artificial e Computacional I e II
- Engenharia de Software I e II
- Probabilidade e Estatística
- Introdução à Ciência de Dados
- Pesquisa Operacional
- Projeto e Análise de Algoritmos (e Algoritmos e Estruturas de Dados)

3.3.2 Justificativa do enquadramento

O desenvolvimento deste trabalho exige a aplicação prática e a integração de diversos conceitos fundamentais do curso de Ciência da Computação:

- Inteligência Artificial e Computacional: Fornece a base teórica essencial para a modelagem, implementação e avaliação das três classes de agentes, heurísticas fixas, Algoritmos Genéticos e Aprendizado por Reforço. Em particular, a formulação do problema como um Processo de Decisão de Markov (MDP) e o projeto da função de recompensa são diretamente derivados dessas disciplinas.

- Engenharia de Software e Algoritmos: A construção de um motor de simulação de alta performance em C++ com interface Python exige domínio de arquitetura de software, programação orientada a objetos, estruturas de dados otimizadas e boas práticas de engenharia. A interface entre as duas linguagens via bindings (pybind11) adiciona uma camada relevante de integração de sistemas.
- Probabilidade e Estatística: Necessária para a modelagem computacional da natureza estocástica do jogo, como a distribuição de probabilidade de aparição de campeões na loja em função do nível, e para a análise estatística dos resultados experimentais entre os agentes.
- Introdução à Ciência de Dados e Pesquisa Operacional: Essenciais para a formulação do problema como um modelo de otimização de recursos e para a coleta, tratamento e análise das métricas geradas nos experimentos (taxa de vitória, colocação média, economia acumulada), validando a eficácia de cada abordagem.

3.4 PLANEJAMENTO DO TRABALHO

A seguir são descritos a metodologia adotada, os recursos disponíveis, as atividades previstas e o cronograma de execução do trabalho.

3.4.1 Metodologia de Desenvolvimento

A metodologia de pesquisa será experimental, dividida em três etapas principais:

1. Engenharia do Ambiente: O motor de simulação será desenvolvido em C++ seguindo o paradigma de Orientação a Objetos, e exposto como biblioteca Python via bindings (pybind11). O ambiente abstrairá a renderização gráfica, focando nas regras de economia (ouro, juros, nivelamento), no sistema de loja estocástico e no combate automático simplificado. Serão implementados aproximadamente 30 campeões com habilidades abstraídas em atributos numéricos, preservando a diversidade de traits e estratégias sem a complexidade de habilidades individuais elaboradas. Essa escolha arquitetural garante que o simulador execute milhares de partidas completas em tempo hábil, viabilizando o treinamento dos agentes.
2. Desenvolvimento dos Agentes: Serão implementadas três classes de agentes em ordem crescente de complexidade. Primeiro, os Agentes de Controle, heurísticas determinísticas fixas como foco máximo em economia ou seleção gulosa de campeões, que estabelecerão o baseline de desempenho. Em seguida, o Agente Evolutivo baseado em Algoritmos Genéticos [Holland 1975; Goldberg 1989], no qual cada indivíduo representa um vetor de pesos de preferência por composições e decisões econômicas, com função de aptidão baseada na colocação final e economia acumulada. Por fim, o Agente de Aprendizado por Reforço, treinado via DQN [Mnih et al. 2015] ou PPO [Schulman et al. 2017], que observará um estado rico do jogo, composição do tabuleiro próprio, unidades no banco, peças disponíveis na loja e composições dos adversários, e aprenderá por interação direta com o simulador a tomar decisões sequenciais ótimas, incluindo quando contestar ou abandonar uma composição com base no estado do lobby.
3. Coleta e Análise de Dados: Os experimentos consistirão em torneios simulados entre as três classes de agentes. Serão coletadas métricas quantitativas ao final de cada execução, taxa de vitória, colocação média, ouro médio e frequência de pivô de composição, para

embasar a análise estatística das estratégias emergentes e validar a hipótese de que o agente de RL supera as abordagens de menor adaptabilidade.

3.4.2 Recursos tecnológicos disponíveis a serem utilizados

- Recursos de Hardware: Computador pessoal (processador AMD Ryzen 5 5600GT, 16GB de RAM e placa de vídeo RX 7600) com capacidade de processamento otimizada para executar múltiplas instâncias da simulação em paralelo e treinar os agentes em tempo hábil.
- Motor de Simulação: Núcleo do ambiente desenvolvido em C++ e exposto como biblioteca Python via pybind11, garantindo a alta performance necessária para o volume de iterações do treinamento por Aprendizado por Reforço. O ambiente seguirá a interface padronizada de ambientes de simulação para RL [Brockman et al. 2016], facilitando a integração com bibliotecas de treinamento existentes.
- Recursos de Software e Ferramentas: Linguagem Python 3 para o desenvolvimento dos agentes e experimentos, com bibliotecas especializadas — PyTorch ou Stable-Baselines3 para o agente de RL; DEAP ou implementação própria para o agente evolutivo. Ambiente de desenvolvimento Visual Studio Code e Git para controle de versionamento.

3.4.3 Atividades Propostas

1. Revisão Bibliográfica, Estudo das Mecânicas do TFT e definição do subconjunto de campeões.
2. Modelagem e Desenvolvimento do Motor de Simulação em C++ com interface Python (pybind11).
3. Implementação e validação dos Agentes de Controle (Heurísticas).
4. Implementação do Agente Evolutivo (Algoritmo Genético).
5. Implementação e treinamento do Agente de Aprendizado por Reforço.
6. Execução dos Experimentos Comparativos e Coleta de Dados.
7. Análise dos Resultados e Escrita da Monografia.

3.4.4 Cronograma proposto

Atividades	Março	Abril	Maio	Junho
1	x			
2	x	x		
3		x		
4			x	
5			x	x
6			x	x
7		x	x	x

3.4.5 Horário proposto destinado à realização do TCC

Horário\Dia	seg.	ter.	quar.	quin.	sex.
8:20 - 9:10					TCC
9:10 - 10:00					TCC
10:10 - 11:00		Aula	Aula		
11:00 - 11:50		Aula	Aula		
13:20 - 14:10					
14:10 - 15:00					
15:10 - 16:00	TCC	TCC	TCC	TCC	
16:00 - 16:50	TCC	TCC	TCC	TCC	

REFERÊNCIAS BIBLIOGRÁFICAS

Holland, J. H. (1975) "Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence", University of Michigan Press, Ann Arbor.

Goldberg, D. E. (1989) "Genetic Algorithms in Search, Optimization, and Machine Learning", Addison-Wesley, Reading.

Sutton, R. S. and Barto, A. G. (2018) "Reinforcement Learning: An Introduction", 2nd ed., The MIT Press, Cambridge.

Mnih, V. et al. (2015) "Human-level control through deep reinforcement learning", Nature, v. 518, n. 7540, p. 529–533. DOI: 10.1038/nature14236.

Schulman, J. et al. (2017) "Proximal Policy Optimization Algorithms", arXiv preprint arXiv:1707.06347. Disponível em: <https://arxiv.org/abs/1707.06347>. Acesso em: 24 nov. 2025.

Brockman, G. et al. (2016) "OpenAI Gym", arXiv preprint arXiv:1606.01540. Disponível em: <https://arxiv.org/abs/1606.01540>. Acesso em: 24 nov. 2025.

Zhang, W. (2024) "Design and implementation of an Intelligent Agent for Auto Battler Games Using Reinforcement Learning", Trabalho de Conclusão de Curso – Lappeenranta-Lahti University of Technology LUT, Lappeenranta. Disponível em: <https://lutpub.lut.fi/handle/10024/167789>. Acesso em: 24 nov. 2025.

Liu, D. (2022) "Computer Knows Best: A Computational Approach to Positioning in Teamfight Tactics", Senior Thesis – Princeton University, Princeton. Disponível em: <https://dataspace.princeton.edu/handle/88435/dsp01nv9356046>. Acesso em: 24 nov. 2025.

Henkel, R. (2019) "Teamfight Tactics has more than 33 million players per month", ONE Esports. Disponível em: <https://www.oneesports.gg/teamfight-tactics/riot-teamfight-tactics-has-more-than-33-million-players-per-month/>. Acesso em: 24 nov. 2025.